

Зг 1/

Синусов Б.А.

1. FLOPS

На вход: $B \times 3 \times S \times S$, при S кратное 16. После каждой операции BN + ReLU, после каждой MaxPool.

Тренировка: $GAP \rightarrow FC(512, 256) \rightarrow ReLU \rightarrow FC(256, 100)$. FP32 в режиме eval, padding = $K//2$, $bices = F_{in}/S$

Слой	K, S	Контакты	элементов
Input	—	3	$3S^2$
Conv1	7, 2	$3 \rightarrow 32$	$8S^2$
Pool	3, 2	$32 \rightarrow 32$	$2S^2$
Conv2	5, 1	$32 \rightarrow 64$	$4S^2$
Conv3	3, 2	$64 \rightarrow 128$	$2S^2$
Conv4	1, 1	$128 \rightarrow 256$	$4S^2$
Conv5	3, 2	$256 \rightarrow 256$	S^2
Conv6	1, 1	$256 \rightarrow 512$	$2S^2$
GAP	—	512	512

$$1 MAC = 2 FLOPS$$

$$BN(eval) = 2 FLOPS/элемент$$

$$ReLU = 1 FLOPS/элемент$$

MaxPool - не учитываем

$$F_{conv} = 2H_{out}W_{out}C_{out}C_{in}K^2$$

$$\text{Для 1 канала: } F_{conv} = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) \cdot S^2 = 14412S^2$$

$$\text{Симметричный размер выхода conv: } (8 + 4 + 2 + 4 + 1 + 2)S^2 = 21S^2 \Rightarrow F_{BN} = 42S^2, F_{ReLU} = 21S^2$$

$$GAP: n = S^2/256, n-1 сложений и 1 деление: F_{GAP} = 512(n-1+1) = 2S^2$$

$$F_{heart} = 2 \cdot 512 \cdot 256 + 256 + 2 \cdot 256 \cdot 100 = 313600 \Rightarrow F(S, B) = B((14412 + 21 + 42 + 2)S^2 + 313600) = B(14477S^2 + 313600)$$

2. Memory

Детализация: FP32, inference mode + eval. Input сохраняется целиком на протяжении для Conv и BN создают новые буферы. ReLU работает in-place. Временный workspace вращаем не дежим

Кол-во элементов в весовых и бинаризах:

$$N_{conv} = 883296, N_{BN} = 4 \cdot (32 + 64 + 128 + 256 + 256 + 512) = 4992, N_{FC} = 154028, N_{static} = 1045316$$

Так активации определяем по одновременно живым тензорам (S^2 на сэмпл):

Синдров
В.А.

Операция	Живые элементы
Conv1	11
BN1	19
ReLU1	11
Pool	13
Conv2/BN2	9/11
Conv3/BN3	9/4
Conv4/BN4	9/11
Conv5/BN5	8/5
Conv6/BN6	6/4

Максимум: BN1: $3S^2 + 8S^2 + 8S^2 = 19S^2$

$$M(S, B) = 4 \cdot (1045316 + 19BS^2), \text{ байт}$$

3. Bytes moved

Допущения: каждая операция 1 раз читает вход и записывает выход.
in-place ReLU также выполняет чтение и запись. Параметры и буферы модели читаем 1 раз за forward.

Логический трафик активаций на 1 сэмпл:

$$\left. \begin{aligned} P_{\text{conv}} &= 34S^2 \\ P_{\text{BN}} &= 42S^2 \\ P_{\text{ReLU}} &= 42S^2 \\ P_{\text{pool}} &= 10S^2 \\ P_{\text{GAP}} &= 2S^2 \end{aligned} \right\} P_{\text{activation}} = 133S^2$$

Остаточный трафик: $512 + 468 + 512 + 356 = 2148$

$P_{\text{static}} = 1045316$

$$P(S, B) = 4 \cdot (133BS^2 + 2148B + 1045316) \text{ байт}$$

1. Latency

$$T_i = \max \left(\frac{F_i}{P_{\text{eff}}}, \frac{P_i}{BW_{\text{eff}}} \right)$$

Допущения: операции последовательны; время определяется вычислительной мощностью; на каждую операцию приходится один запуск CUDA-ядра; частота поставок; FP32, TF32 отключен.

Число запусков: $6_{\text{conv}} + 6_{\text{BN}} + 6_{\text{ReLU}} + 1_{\text{pool}} + 1_{\text{GAP}} + 3_{\text{head}} = 23$

$$T(S, B, \theta) = \sum_{i=1}^{23} \max \left(\frac{F_i}{P_{\text{eff}}}, \frac{P_i}{BW_{\text{eff}}} \right) + 23t_{\text{launch}}, \text{ с}$$

Калибровка:

$$P_{\text{eff}} = 6,11 \cdot 10^{12} \text{ FLOPS}$$

$$BW_{\text{eff}} = 83,6 \cdot 10^9 \text{ байт/с}$$

$$t_{\text{launch}} = 49,2 \text{ нс}$$

5. Energy

Смирнов В.А.

$$E_{\text{forward}} = \frac{\Delta E}{K}$$

Функция: учитывается общее потребление энергии, включая факт; энергия аппроксимируется отдельной функцией FLOPS и логического трафика; влияние частот и напряжений включено в калибровочные коэффициенты.

$$E(S, B, \theta') = C_0 + C_f F(S, B) + C_b D(S, B)$$

Калибровка:

$$C_0 = 0,464 \text{ Дж}$$

$$C_f = 247 \cdot 10^{-9} \text{ Дж/FLOPS}$$

$$C_b = -9,1173 \cdot 10^{-8} \text{ Дж/байт}$$

Для малых нагрузок максим есть постоянный вклад:

$$C_0 + 4C_b \cdot 1045316 \approx 0,0832 \text{ Дж.}$$